

Un modelo de Markov para la segmentación automática de señales de audio

Rafael de Jesús Robledo Juárez

`rrobledo@cimat.mx`

Asesor: Dr. Salvador Ruíz Correa

Departamento de Ciencias de la Computación
Centro de Investigación en Matemáticas, Guanajuato



CIMAT

Presentación de Avance de Tesis, 2013



Outline

1 Introducción

- Motivación
- Trabajo previo

2 Procesamiento señal de audio

- Preprocesamiento
- Obtención de vector de características

3 Modelo

- Hidden Markov Model
- Resolver HMM con EM
- Bootstrap

4 Pruebas

- Pruebas con datos sintéticos

5 Trabajo futuro



Motivación

- ▶ La segmentación automática de una señal de audio en zonas homogéneas de acuerdo a las personas que hablan se conoce como *speaker diarization*.
- ▶ Es una etapa importante en el procesamiento de voz. Tanto para reconocimiento como transcripción de voz.
- ▶ Es un problema interesante para modelar, pues no se puede considerar que se tiene información a priori.




Trabajo previo

You can create overlays. . .

- ▶ using the `pause` command:
 - ▶ First item.
 - ▶ Second item.
- ▶ using overlay specifications:
 - ▶ First item.
 - ▶ Second item.
- ▶ using the general `uncover` command:
 - ▶ First item.
 - ▶ Second item.






Eliminación de ruido / Detección de silencios



Mel Frequency Cepstrum Coefficient

- FFT (ventana) -> Banco de filtros triangular (Mel Scale) -> Log -> DCT -> MFCC




Hidden Markov Model

- Cadena de Markov de primer orden



$$p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | x_1, \dots, x_{n-1}) = p(x_1) \prod_{n=2}^N p(x_n | x_{n-1}) \quad (1)$$

- Modelo estocástico de Markov en el que el estado de la cadena es parcialmente observado.



- Modelar proceso bivariado en el tiempo. Una variable observada y una variable latente asociada.

Hidden Markov Model

- Agregar una variable latente z_n (discreta), que corresponda a cada observación x_n .

$$z_{n+1} \perp z_{n-1} \mid z_n \quad (2)$$

$$p(x_1, \dots, x_N, z_1, \dots, z_N) = p(z_1) \left[\prod_{n=2}^N p(z_n \mid z_{n-1}) \right] \prod_{n=1}^N p(x_n \mid z_n). \quad (3)$$

- Mezcla de distribuciones en la que la densidad tiene una distribución dada por $p(x|z)$



Parámetros del HMM

- Probabilidad de cambio entre estados dada una **matriz de transición \mathbf{A}**

$$A_{jk} \equiv p(z_{nk} = 1 \mid z_{n-1,j} = 1) \quad (4)$$

$$p(z_n \mid z_{n-1}, \mathbf{A}) = \prod_{k=1}^K \prod_{j=1}^K A_{jk}^{z_{n-1,j} \cdot z_{n,k}} \quad (5)$$

- **Vector de distribución inicial π** para variable latente.

$$\pi_k \equiv p(z_{1k}) \quad (6)$$

$$p(z_1 \mid \pi) = \prod_{k=1}^K \pi_k^{z_{1k}} \quad (7)$$

- **Probabilidad de emisión** de una variable observada x_n dada una variable latente z_n .

$$p(x_n \mid z_n, \phi) = \prod_{k=1}^K p(x_n \mid \phi_k)^{z_{nk}} \quad (8)$$



HMM con EM

- Probabilidad conjunta del modelo

$$p(\mathbf{X}, \mathbf{Z} \mid \theta) = p(z_1 \mid \pi) \left[\prod_{n=2}^N p(z_n \mid z_{n-1}, \mathbf{A}) \right] \prod_{n=1}^N p(x_n \mid z_n, \phi) \quad (9)$$

- Parámetros del modelo $\theta = \{\pi, \mathbf{A}, \phi\}$
- Función de verosimilitud completa

$$\mathcal{Q}(\theta, \theta^{old}) = \sum_{\mathbf{Z}} p(\mathbf{Z} \mid \mathbf{X}, \theta^{old}) \log p(\mathbf{X}, \mathbf{Z} \mid \theta) \quad (10)$$

- Prob. marginal de una variable latente, prob. conjunta de dos variables latentes consecutivas

$$\gamma(z_n) = p(z_n \mid \mathbf{X}, \theta^{old}) \quad (11)$$

$$\xi(z_{n-1}, z_n) = p(z_{n-1}, z_n \mid \mathbf{X}, \theta^{old}) \quad (12)$$



HMM con EM

- Prob. marginal de $z_{nk} = 1$, prob. conjunta de $z_{n-1,j}, z_{nk}$

$$\gamma(z_{nk}) = \mathbb{E}[z_{nk}] = \sum_{\mathbf{z}} \gamma(\mathbf{z}) z_{nk} \quad (13)$$

$$\xi(z_{n-1,j}, z_{nk}) = \mathbb{E}[z_{n-1,j} \cdot z_{nk}] = \sum_{\mathbf{z}} \gamma(\mathbf{z}) z_{n-1,j} \cdot z_{nk} \quad (14)$$

- Función de verosimilitud completa (reescrita con (13), (14))

$$\begin{aligned} Q(\theta, \theta^{old}) = & \sum_{k=1}^K \gamma(z_{1k}) \log \pi_k + \sum_{n=2}^N \sum_{j=1}^K \sum_{k=1}^K \xi(z_{n-1,j}, z_{nk}) \log A_{jk} + \\ & \sum_{n=1}^N \sum_{k=1}^K \gamma(z_{nk}) \log p(x_n | \phi_k) \end{aligned} \quad (15)$$

- Parámetros estimados por EM:

$$\pi_k = \frac{\gamma(z_{1k})}{\sum_{j=1}^K \gamma(z_{1j})}, \quad A_{jk} = \frac{\sum_{n=2}^N \xi(z_{n-1,j}, z_{nk})}{\sum_{l=1}^K \xi(z_{n-1,j}, z_{nl})} \quad (16)$$



Algoritmo backward-forward

$$\gamma(z_n) = p(z_n | X) = \frac{p(X | z_n)p(z_n)}{p(X)} \quad (17)$$

$$\gamma(z_n) = \frac{p(x_1, \dots, x_n, z_n)p(x_{n+1}, \dots, x_N | z_n)}{p(X)} \quad (18)$$

$$\gamma(z_n) = \frac{\alpha(z_n)\beta(z_n)}{p(X)} \quad (19)$$

$$(20)$$

donde

$$\alpha(z_n) \equiv p(x_1, \dots, x_n, z_n) \quad (21)$$

$$\beta(z_n) \equiv p(x_{n+1}, \dots, x_N | z_n) \quad (22)$$

$$\alpha(z_n) = p(x_n | z_n) \sum_{z_{n-1}} \alpha(z_n | z_{n-1}) \quad (23)$$

$$\alpha(z_1) = p(z_1)p(x_1 | z_1) = \prod_{k=1}^K \{\pi_k p(x_1 | \phi_k)\}^{z_{1k}} \quad (24)$$



Algoritmo backward-forward

$$\beta(z_n) = \sum_{z_{n+1}} \beta(z_{n+1}) p(x_{n+1} \mid z_{n+1}) p(z_{n+1} \mid z_n) \quad (25)$$



Bootstrap



Numero fijo de speakers



Numero variable de speakers



Resumen



- ▶ The **first main message** of your talk in one or two lines.
 - ▶ The **second main message** of your talk in one or two lines.
 - ▶ Perhaps a **third message**, but not more than that.
-
- ▶ Outlook
 - ▶ Something you haven't solved.
 - ▶ Something else you haven't solved.



Trabajo futuro



Referencias I

-  A. Author.
Handbook of Everything.
Some Press, 1990.
-  S. Someone.
On this and that.
Journal of This and That, 2(1):50–100, 2000.

